

연구 A - 논문 계획서 (석사과정)

주임교수

논문제목	국 문	비대칭 임상 데이터 환경에서의 피부암 분류를 위한 Strict 정보 기반 다중모달 융합과 보조 오라클 감독학습
	영 문	Strict-Information-Based Multimodal Fusion with Auxiliary Oracle Supervision for Skin Cancer Classification in Asymmetric Clinical Data Settings

2026년 04월 08일

정보통신대학원 석사과정 1학기

전 공 : 인공지능

학 번 : 202533156

성 명 : 김준 (인)

지도교수 : 김소연 (인)

공동지도교수 : (인)

1. 연구주제 및 연구의 필요성(1page 이상)

1. 연구주제

본 연구의 주제는 ISIC 2024/Slice-3D 환경에서, 추론 시점에 실제로 확보 가능한 병변 이미지와 strict tabular input만으로 피부암 악성 여부를 예측하되, 학습 단계에서만 확인 가능한 병리 진단 문자열(iddx_full)을 선택적 auxiliary oracle supervision으로 활용하여 성능과 설명가능성을 동시에 높이는 실제 배치형 멀티모달 분류 프레임워크를 설계·검증하는 것이다. 구체적으로는 이미지-tabular cross-attention 기반의 base representation을 형성하고, pathology-informative subset에 한정된 oracle supervision을 통해 병리의 의미 구조를 간접적으로 반영하며, correction head 또는 prototype-weighted 보정 구조를 통해 최종 분류 안정성을 높이는 방식을 탐구한다. 이는 실제 배치 가능한 입력 조건과 학습 단계의 추가 지식 활용을 분리해서 다룬다는 점에서 기존 멀티모달 피부암 분류 연구와 구별되는 문제 설정이다.

2. 연구의 필요성

1) 문제 배경

피부암은 조기 발견과 신속한 triage가 예후에 큰 영향을 미치는 질환이며, 최근에는 3D total body photography(3D-TBP) 기반의 대규모 피부 병변 데이터가 공개되면서 실제 진료 흐름에 더 가까운 환경에서 인공지능 모델을 연구할 수 있게 되었다. 특히 SLICE-3D는 3D-TBP에서 추출한 40만 개 이상의 피부 병변 crop으로 구성된 대규모 데이터셋이며, ISIC 2024 challenge의 공식 학습 데이터셋으로 사용되었다. 또한 해당 과제는 각 병변 영상에 대해 악성 확률을 예측하는 문제로 설정되어 있어, 실제 임상에서 사용 가능한 영상 기반 보조진단 모델을 검토하기에 적절한 연구 환경을 제공한다.

한편 최근 의료 인공지능 연구에서는 이미지와 구조화된 임상 데이터를 함께 사용하는 멀티모달 융합이 단일 모달 접근보다 더 풍부한 표현을 형성할 수 있다는 점이 꾸준히 보고되고 있다. 특히 attention 기반 intermediate fusion, cross-attention 기반 융합, 설명가능성을 동반한 multimodal framework 등은 의료 분류 문제에서 유망한 방향으로 정리되고 있으며, 피부 병변 분야에서도 이미지와 메타데이터를 함께 사용할 때 성능과 해석 가능성이 모두 개선될 수 있음이 제시되고 있다.

그러나 실제 임상 워크플로우에서는 모든 정보가 동시에 주어지지 않는다. 첨부 초안이 전제하듯이, 추론 시점에는 병변 이미지와 strict tabular input은 확보 가능하지만, 병리 결과를 요약한 idx_full과 같은 정보는 사후적으로만 확인되거나 학습 데이터에서만 관찰된다. 따라서 본 연구 문제는 단순히 “더 많은 정보를 넣으면 성능이 올라가는가”가 아니라, 실제 추론 입력 조건을 유지하면서도 학습 단계의 추가 지식을 어떻게 간접적으

로 활용할 것인가라는 방향으로 재정의될 필요가 있다.

2) 연구 공백 및 필요성

기존 멀티모달 피부 병변 연구들은 대체로 학습과 추론에서 동일한 modality set이 유지된다는 가정 아래 이미지와 메타데이터를 결합한다. 하지만 최근 멀티모달 의료영상 융합 리뷰는 incomplete modality 관리 자체가 여전히 핵심 난제임을 지적하고 있으며, 실제 배치 조건을 유지한 채 train-time only 정보를 활용하는 프레임은 충분히 정립되어 있지 않다. 다시 말해, 기존 연구는 “무엇을 함께 넣어 성능을 높일 것인가”에는 강하지만, “추론 시점에 사라지는 정보를 학습에서만 어떻게 활용할 것인가”라는 비대칭적 문제 설정에는 상대적으로 약하다.

이 지점에서 본 연구의 필요성이 발생한다. Learning using privileged information(LUPI)와 generalized distillation 연구는 시험 단계에 없는 추가 정보를 학습 단계에서만 활용하여 일반화 성능을 향상시킬 수 있음을 이론적으로 보여주었지만, 이를 피부암 멀티모달 분류에서 “병리 문자열은 입력이 아니라 auxiliary supervision”으로 재구성한 연구는 드물다. 더욱이 첨부 초안이 지적하듯이 iddx_full은 전 샘플에 존재하더라도 대다수가 동일한 “Benign” 문자열에 편중되어 있어, 병리 의미는 소수의 pathology-informative subset에 집중된다. 따라서 이 정보를 단순 입력으로 결합하는 방식은 정보 붕괴나 편향을 유발할 수 있으며, 선택적 auxiliary supervision과 보정 모듈을 통해 안정적으로 반영하는 별도의 설계가 필요하다.

3. 기대 기여

첫째, 본 연구는 학습 단계에서만 이용 가능한 병리 진단 문자열을 train-time privileged information으로 재해석하고, 이를 추론 입력에 직접 포함하지 않는 선택적 auxiliary oracle supervision 구조로 정식화함으로써, 실제 배치 가능성과 추가 지식 활용을 분리한 피부암 멀티모달 학습 프레임을 제안한다. 이는 LUPI 개념을 피부암 3D-TBP 기반 악성도 분류 문제에 맞게 구체화한 방법론적 기여가 된다.

둘째, 본 연구는 image-only, strict tabular-only, multimodal base, no-oracle/oracle, no-correction/correction/prototype-weighted 구조를 단계적으로 비교함으로써, 멀티모달 융합 자체의 효과, oracle supervision의 효과, 보정 구조의 안정화 효과를 분리해 검증할 수 있는 실험 설계를 제시한다. 특히 tabular branch에 FT-Transformer 계열의 강한 기준 모델을 두고 비교한다는 점에서, 결과 해석의 엄밀성과 재현 가능성을 높일 수 있다.

셋째, 본 연구는 추론 시점에 실제로 사용 가능한 입력만 남기면서도 학습 단계의 병리

의미 구조를 간접 반영하도록 설계되어, 단순 성능 향상보다 실제 임상 triage와 배치 가능성을 우선하는 연구라는 점에서 실용적 기여를 가진다. 특히 SLICE-3D/ISIC 2024와 같이 대규모 3D-TBP 환경에서 이러한 설정을 검증한다는 점은 데이터셋 활용 측면에서도 의미가 있다.

넷째, 본 연구는 이미지 branch의 CAM/attention 기반 시각화, tabular branch의 SHAP 분석, 그리고 auxiliary oracle supervision이 학습한 cluster 반응을 함께 분석함으로써, 모델이 어떤 시각적 단서와 어떤 구조화 변수, 어떤 병리 의미 축에 반응하는지를 다층적으로 설명할 수 있다. 이는 의료 인공지능에서 중요한 설명가능성, 신뢰성, 임상 수용성을 함께 평가할 수 있는 기반이 된다.

II. 연구내용 및 연구방법(1page 이상)

■ 연구 내용

본 연구는 실제 임상 적용 가능성을 고려하여, 추론 시점에 확보 가능한 이미지와 strict tabular input만으로 피부암 악성 여부를 분류하는 멀티모달 모델을 구축하고자 한다. 동시에 학습 단계에서만 확인 가능한 병리 진단 문자열(iddx_full)은 입력으로 사용하지 않고 auxiliary oracle supervision으로만 활용하여, 추론 입력을 바꾸지 않으면서도 병리 의미 구조를 간접적으로 반영하도록 설계한다. 본 연구의 핵심은 실제 배치 가능성과 학습 단계의 추가 지식 활용을 분리하여 다루는 데 있다.

모델은 세 단계로 구성된다. 첫째, 이미지와 strict tabular input으로부터 기본 판별 표현인 F_{base} 를 형성한다. 둘째, iddx_full로부터 병리 의미 구조를 추출하고, Auxiliary Oracle Head가 이를 예측하도록 학습하여 F_{base} 가 병리 구조와 일정 부분 정렬되도록 유도한다. 셋째, Correction Head 또는 대안적 prototype-weighted 보정 구조를 통해 F_{base} 를 최종 분류에 더 유리한 방향으로 조정한다. 여기서 Correction Head는 직접적인 target residual을 복원하는 모듈이 아니라, strict 입력으로부터 추정된 representation-level correction vector를 이용해 base representation을 보정하는 모듈로 정의한다. 또한 prototype-weighted 구조는 자동 fallback이 아니라, Correction Head의 안정성을 비교하기 위한 대안적 보정 구조로 설정한다.

■ 연구 방법

1. 데이터 정의 및 분할 전략

본 연구의 최종 예측 대상은 iddx_1을 기준으로 정의한 이진 분류 target이다. 구체적으로 iddx_1 = Malignant는 1, iddx_1 $\in$ {Benign, Indeterminate}는 0으로 정의한다. 이 정의는 실제 임상에서 중요한 악성 여부 판단에 초점을 맞춘 것이다.

평가는 환자 단위 분리를 전제로 한 Triple Stratified K-Fold 검증으로 수행한다. 폴드 구성 시에는 타깃 라벨 분포, 환자별 악성 병변 보유 여부, 환자별 병변 수를 함께 고려하여 특정 폴드 편향을 줄인다. 각 outer fold의 학습 데이터는 다시 internal train과 validation으로 나누어 하이퍼파라미터 선택과 early stopping에 사용하고, 해당 fold의 test split은 최종 평가에만 사용한다. 또한 동일 환자의 샘플이 서로 다른 split에 동시에 포함되지 않도록 환자 단위 그룹 분할을 적용한다. 모든 전처리와 보조 타깃 생성 절차는 각 fold의 training split에서만 적합하며, validation과 test split에는 적합된 변환만 적용한다.

2. strict 입력 구성 및 전처리

본 연구의 입력은 실제 추론 가능성을 기준으로 이미지와 strict tabular input으로 제한한다. strict tabular input은 실제 추론 단계에서 직접 관측 가능한 원시 임상 메타데이터(strict raw)와, 이로부터 명시적으로 생성되며 추론 시점에도 계산 가능한 파생 변수(strict feature-engineering)로 구성한다. 본 연구의 주 실험에서는 tabular 입력을 $X_{\text{strict}} = [X_{\text{raw}}; X_{\text{fe}}]$ 로 고정한다. strict raw only와 strict FE only 비교는 입력 구성의 예비 검토 또는 부록 분석으로 제한하고, 메인 비교 실험에서는 사용하지 않는다.

수치형 변수는 fold 내부 training split 기준으로 중앙값 대체와 결측 indicator를 적용한다. 범주형 변수의 결측은 별도 "Missing" 범주로 유지하고, 이후 학습 가능한 임베딩으로 변환한다. 파생 변수는 모두 생성식이 명시 가능해야 하며, 추론 시점에 사용할 수 없는 정보를 포함해서는 안 된다. 또한 수치형 스케일링, 범주형 인코딩, 결측 처리 등 모든 전처리 절차는 training split에서만 적합한다.

3. 멀티모달 base model과 baseline 구성

이미지 branch는 사전학습된 비전 인코더를 사용하여 병변 이미지를 임베딩하고, 대표 시각 표현으로는 CLS token 또는 이에 준하는 전역 표현을 사용한다. tabular branch는 FT-Transformer를 사용하여 X_{strict} 를 임베딩한다. 본 연구의 주 멀티모달 모델은 이미지 표현과 tabular 표현을 cross-attention으로 융합하여 base representation F_{base} 를 형성한다.

비교 실험의 기준 모델은 세 가지로 구성한다. 첫째, image-only baseline은 동일한 이미지 인코더와 분류기를 사용하되 tabular 입력을 사용하지 않는다. 둘째, strict tabular-only baseline은 동일한 FT-Transformer와 분류기를 사용하되 입력을 $X_{\text{strict}} = [X_{\text{raw}}; X_{\text{fe}}]$ 로 고정한다. 셋째, multimodal base model은 이미지와 X_{strict} 를 함께 사용하되 oracle supervision과 correction module은 포함하지 않는다. 추가로 cross-attention의 타당성을 점검하기 위한 참조 baseline으로 simple concatenation 기반 multimodal model을 1회 비교한다.

4. 선택적 Auxiliary Oracle Supervision

본 연구에서 idxx_full 은 전 샘플에 존재하지만, 대부분의 샘플이 동일한 "Benign" 문자열로 구성되어 있어 전체 텍스트 분포의 의미 다양성은 병리 기술이 포함된 일부 샘플에 집중되어 있다. 따라서 본 연구는 idxx_full 전체를 동일한 수준의 oracle text로 다루지 않고, 병리 의미가 실제로 존재하는 샘플 subset에 대한 선택적 auxiliary oracle supervision으로 재정의한다.

구체적으로는 $\text{idxx_full} \neq \text{"Benign"}$ 인 샘플만 pathology-informative subset으로 정의한

다. 이 subset의 training split에 대해서만 lowercasing, 구분 기호 정규화, n-gram 기반 TF-IDF 벡터화, Truncated SVD 차원 축소를 수행하고, 이후 K-means clustering을 통해 oracle cluster를 구성한다. cluster 개수는 training split 내부에서 실루엣 점수와 최소 cluster 크기 기준을 함께 고려하여 결정한다. 이때 TF-IDF vocabulary, SVD basis, K-means centroid는 모두 training split에서만 적합하고 validation 및 test split에는 적용된 변환만 적용한다.

Auxiliary Oracle Head는 F_{base} 에서 분기되어 해당 oracle cluster를 예측하도록 학습된다. 보조 손실은 class-balanced cross-entropy를 사용하며, pathology-informative subset에 대해서만 적용한다. 반면 $id_{full} = \text{"Benign"}$ 인 샘플은 주 분류 손실에만 참여시켜, auxiliary task가 거대 benign class 예측으로 붕괴하는 것을 방지한다. 또한 pathology-informative subset의 비율이 매우 낮기 때문에, 학습 과정에서는 해당 샘플이 batch에 안정적으로 포함되도록 sampling ratio를 보정한다.

5. 저차원 Correction Head와 대안적 Prototype-Weighted 보정 구조

본 연구의 Correction Head는 명시적인 teacher residual target을 직접 맞추는 모듈이 아니다. 대신 strict 입력으로부터 저차원 보정 표현을 추정하고, 이를 base representation 차원으로 사상하여 최종 보정 벡터를 생성한다. 최종 표현은 $F_{final} = F_{base} + \hat{r}$ 형태로 구성한다. 여기서 $\hat{r}$ 은 직접적인 target residual이 아니라, strict 입력 기반의 representation-level correction vector이다. 즉, Correction Head의 목적은 F_{base} 를 최종 분류에 더 적합한 방향으로 미세 조정하는 데 있다.

대안 구조로는 prototype-weighted 보정 모델을 함께 둔다. 이 구조는 Correction Head가 실패할 때 자동으로 전환되는 fallback이 아니라, Correction Head의 안정성을 비교하기 위한 별도 실험군이다. prototype은 pathology-informative subset에서 형성된 oracle cluster 또는 의미 공간으로부터 유도하며, student branch는 각 prototype의 가중치를 예측하여 이를 보정 항으로 사용한다. 이때 benign에 가까운 샘플이 과도한 보정을 받지 않도록 null prototype 또는 no-correction prototype을 함께 둔다.

6. 학습 전략 및 비교 실험

분류 손실은 weighted BCE를 기본으로 사용한다. 전체 목적함수는 주 분류 손실과 auxiliary oracle loss의 가중합으로 구성하며, Correction Head가 포함되는 경우에는 보정 벡터의 크기를 제어하기 위한 규제항을 추가한다. 본 연구의 비교 실험은 가설 검증 중심으로 단계화한다.

첫 번째 단계에서는 image-only, strict tabular-only, multimodal base model을 비교하

여 multimodal 자체의 효과를 검증한다. 두 번째 단계에서는 동일한 multimodal backbone과 동일한 추론 입력을 유지한 상태에서 no-oracle 모델과 auxiliary oracle supervision 포함 모델을 비교하여 oracle supervision의 기여를 평가한다. 세 번째 단계에서는 auxiliary oracle supervision이 포함된 모델을 기준으로 no-correction, Correction Head, alternative prototype-weighted correction branch를 비교하여 보정 구조의 효과와 안정성을 평가한다.

7. 평가 지표 및 설명 가능성 분석

본 연구의 주평가 지표는 희귀 양성 탐지 문제에 적합한 pAUC로 설정한다. pAUC는 미리 정의한 low-FPR 구간에서 계산하며, 부평가 지표로는 Average Precision, ROC-AUC, Balanced Accuracy를 함께 사용한다. 또한 평균 성능뿐 아니라 fold 간 표준편차와 minimum fold pAUC를 함께 보고하여 성능 안정성을 평가한다.

설명 가능성 분석은 이미지 branch와 tabular branch를 분리하여 수행한다. 이미지 branch는 CAM 계열 시각화 또는 attention map을 활용하여 병변의 어떤 영역이 예측에 영향을 주는지 확인한다. tabular branch는 SHAP을 중심으로 변수 기여도를 분석하고, attention weight는 보조적 해석 수단으로만 활용한다. 또한 auxiliary oracle supervision이 포함된 모델에서는 예측된 oracle cluster와 주요 입력 반응을 함께 분석하여, 모델이 단순한 상관관계가 아니라 병리 의미 구조를 어느 정도 반영하고 있는지 점검한다.

8. 연구 흐름의 종합 정리

정리하면, 본 연구는 먼저 실제 추론에서 사용 가능한 이미지와 strict tabular input으로 multimodal base model을 구축한다. 다음으로 학습 단계에서만 확인 가능한 iddx_full로부터 병리 의미 구조를 추출하여 선택적 auxiliary oracle supervision을 수행한다. 마지막으로 Correction Head 또는 대안적 prototype-weighted 보정 구조를 통해 base representation을 최종 분류에 더 유리한 방향으로 보정한다. 이를 통해 실제 배치 가능한 입력 조건을 유지하면서도 학습 단계의 병리 지식을 간접적으로 활용하는 피부암 멀티모달 분류 프레임워크를 제안하고자 한다.

III. 참고문헌

1. Gorishniy, Y., Rubachev, I., Khrulkov, V., & Babenko, A. (2021). Revisiting Deep Learning Models for Tabular Data. *Advances in Neural Information Processing Systems*, 34, 18932–18943.
2. ISIC Archive. (2024). Home – ISIC 2024 Challenge Dataset. Retrieved April 8, 2026.
3. Kurtansky, N. R., D'Alessandro, B. M., Gillis, M. C., et al. (2024). The SLICE-3D dataset: 400,000 skin lesion image crops extracted from 3D TBP for skin cancer detection. *Scientific Data*, 11, 884. doi:10.1038/s41597-024-03743-w.
4. Li, Y., Daho, M. E. H., Conze, P.-H., Zeghlache, R., Le Boité, H., Tadayoni, R., Cochener, B., Lamard, M., & Quellec, G. (2024). A review of deep learning-based information fusion techniques for multimodal medical image classification. *Computers in Biology and Medicine*, 177, 108635. doi:10.1016/j.compbiomed.2024.108635.
5. Lopez-Paz, D., Bottou, L., Schölkopf, B., & Vapnik, V. (2016). Unifying distillation and privileged information. In *International Conference on Learning Representations (ICLR)*.
6. Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.
7. Tran-Van, N.-Y., & Le, K.-H. (2025). A multimodal skin lesion classification through cross-attention fusion and collaborative edge computing. *Computerized Medical Imaging and Graphics*, 124, 102588. doi:10.1016/j.compmedimag.2025.102588.
8. Vapnik, V., & Vashist, A. (2009). A new learning paradigm: Learning using privileged information. *Neural Networks*, 22(5–6), 544–557. doi:10.1016/j.neunet.2009.06.042.
9. Wang, Z., Tai, M., Hu, H., Yuan, H., Wang, C., Fu, H., et al. (2025). Explainable multimodal AI for skin lesion risk prediction via 3D imaging and clinical data. *Scientific Reports*, 15, 45139. doi:10.1038/s41598-025-33536-z.
10. Cheslerean-Boghiu, T., Fleischmann, M.-E., Willem, T., & Lasser, T. (2023). Transformer-based interpretable multi-modal data fusion for skin lesion classification. *CoRR*, abs/2304.14505. doi:10.48550/arXiv.2304.14505.
11. Kaggle. (2024). ISIC 2024 – Skin Cancer Detection with 3D-TBP. Retrieved April 8, 2026.