

연구 A - 논문 계획서 (석사과정)

주임교수

논문제목	국 문	비대칭적 임상 데이터 환경에서의 초희소 오라클 지식 증류: 파생변수와 베이지안 초기화 및 잔차 추정 기반 다중모달 융합 네트워크 (BORE)
	영 문	Distilling Extremely Sparse Oracle Knowledge in Asymmetric Clinical Data: Multimodal Fusion Network based on Bayesian Initialization and Residual Estimation using Engineered Features

2026년 04월 07일

정보통신대학원 석사과정 1학기

전 공 : 인공지능

학 번 : 202533156

성 명 : 김준 (인)

지도교수 : 김소연 (인)

공동지도교수 : (인)

1. 연구주제 및 연구의 필요성(1page 이상)

1. 문제 배경: 임상 데이터의 구조적 비대칭성

최근 피부암(Melanoma) 진단 등 의료 인공지능(AI) 분야에서는 임상 이미지와 정형 데이터를 결합하는 다중모달 학습이 주요하게 연구되고 있습니다. 그러나 실제 진단 워크플로우에는 데이터 수집 시점의 비대칭성이 존재합니다. 진찰 초기에는 이미지와 초기 임상 정보, 그리고 이를 바탕으로 구성 가능한 구조화 파생변수만 활용 가능한 반면, 질병의 확진을 나타내는 '오라클(Oracle) 정보(예: 세부 병리 유형)'는 생검 이후에야 확보됩니다. 결과적으로 AI가 실제 임상 현장에서 추론을 수행할 때(Test Phase), 모델이 활용할 수 있는 핵심 정보가 결측되는 구조적 한계에 직면하게 됩니다.

2. 연구 공백: 초희소 오라클 정보로 인한 기존 방법의 제약

본 연구가 다루는 ISIC 2024 데이터셋의 경우, 유의미한 오라클 데이터(iddx_full)가 기록된 표본은 전체 학습 데이터의 약 0.98% 수준으로 매우 드뭅니다. 이러한 초희소 환경에서 기존의 딥러닝 방법론을 그대로 적용할 경우, 모델이 유의미한 패턴을 학습하지 못하는 '콜드 스타트(Cold Start)' 현상이나 소수 데이터에 대한 과적합 위험이 높아질 수 있습니다. 이를 우회하기 위해 결측치를 평균값으로 단순 대체(Imputation)하거나 대형 언어 모델(LLM)을 활용하는 연구들도 제안되었으나, 이는 병리학적 맥락을 충분히 반영하지 못하거나 한정된 데이터 환경에서 한정된 표본 환경에서는 오히려 불안정성과 노이즈를 키울 우려를 초래할 우려가 있습니다.

3. 연구 필요성: 정보 누수 방지 및 효율적 프레임워크의 요구

따라서 1% 미만의 희소 데이터 환경에서 모델의 성능을 확보하기 위해서는, 정보 누수(Leakage)를 엄격히 통제하면서도 임상적 도메인 지식을 효과적으로 반영할 수 있는 접근이 필요합니다. 특히, 계층적 구조를 띠는 병리 데이터의 특성을 고려할 때, 모델의 복잡도를 불필요하게 높이지 않으면서도 데이터의 본질적인 구조를 학습할 수 있는 효율적인 프레임워크 설계가 요구됩니다. 즉, 추론 시점에 실제로 확보 가능한 정보만으로도 기본 진단이 가능하고, 오라클 정보는 직접 입력이 아니라 제한적 학습 신호로 활용되는 구조가 필요합니다.

4. 본 연구의 방향 및 핵심 기여: BORE 프레임워크 제안

이에 본 연구는 추론 시 결측되는 오라클 정보를 직접 예측하는 대신, 획득 가능한 기본 지식(파생변수 및 이미지)과 오라클 지식 간의 차이인 '가상의 잔차(Residual)'를 추정하는 BORE (Bayesian-initialized Oracle Residual Estimation) 프레임워크를 제안합니다. 본 연구의 주요 기여는 다음과 같습니다.

- 학습 안정성 향상 가능성 제시: 베이지안 통계 기반의 초기화 기법을 적용하여 희소 데이터 환경에서의 초기 학습 불안정성을 완화합니다.
- 추론 시 강건성 확보 구조 검증: 잔차 추정 오차가 발생하더라도 파생변수 기반의 어텐션 구조가 기본 성능의 하한선(Lower Bound)을 유지할 수 있도록 돕는 구조적 이점을 검증합니다.
- 설명 가능성 기반 해석 체계 제시: 모델의 예측이 임상적 특징에 어떻게 반응하는지 시각화하여, 진단 보조 도구로서의 해석 가능성을 제시합니다.

결과적으로 본 연구는 극소수의 정답 데이터(0.98%)만으로도 강건한 추론이 가능함을 증명하여, 다중모달 의료 AI가 실제 임상 현장에 도입되기 위한 실효성 있는 대안을 제시하고자 합니다.

II. 연구내용 및 연구방법(1page 이상)

■ 연구 목표

전체 학습 데이터의 0.98%에 불과한 희소 오라클 병리 소분류 데이터(iddx_full의 52개 계층적 범주)의 한계를 극복하기 위해, 추론 시점에 획득 가능한 피부 병변 이미지와 k 개의 파생변수로 구성된 엄격한 정형 데이터(Strict Feature Engineering Dataset)만을 활용하여 피부암(Melanoma)을 정확히 분류해 내는 딥러닝 아키텍처 BORE (Bayesian-initialized Oracle Residual Estimation)를 개발하고 그 구조적 안정성을 검증한다.

■ 연구 방법 및 단계별 아키텍처

본 연구는 다음과 같은 4단계의 아키텍처 흐름으로 진행됩니다.


Step 1. 변수 통제 및 베이지안 사전 지식 주입 (초기화 단계)

0.98%의 극소수 데이터로 인한 '콜드 스타트(Cold Start)' 현상을 막기 위해, 통계적 확률을 네트워크 내부 다중모달 융합 층의 학습 가능한 프로토타입 토큰(Learnable Prototype Tokens, P_k)의 초기 가중치로 직접 주입한다.

1. 사전 확률 추출: 다양한 iddx_full 범주가 포함되도록 샘플링된 데이터 영역에서, 나이브 베이즈 정리를 이용해 k 개의 병리 카테고리별로 파생변수들의 결합 확률 분포 벡터 v_k 를 산출한다. 이때 v_k 는 N 개 파생변수의 통계값을 나열한 $N \times 1$ 형태의 차원을 갖는다.
2. 잠재 공간 투영 및 가중치 삽입: 산출된 $N \times 1$ 크기의 v_k 를 D 차원의 트랜스포머 잠재 공간으로 투영하기 위해 크기 $D \times N$ 의 투영 행렬 W_{proj} 를 통과시킨다. 이때 W_{proj} 는 무작위(Random) 값이 아닌, Masked Tabular Modeling을 통해 파생변수의 문맥을 이미 사전 학습(Pre-training)한 정형 인코더(FT-Transformer)의 가중치를 활용하여 베이지안 사전 지식의 소실을 방어한다. ($P_k = W_{proj} \cdot v_k + b$)

Step 2. 베이스 지식의 추출 (F_{base}) 및 조건부 동적 융합

실제 진찰 시점에도 정보 누수(Leakage) 없이 확실히 얻을 수 있는 "견고한 기본 지식"을 추출한다. 두 모달리티를 단순 결합(Concat)하는 대신, 최신 다중모달 트렌드에 부합하는 Cross-Attention 구조를 채택하여 조건부 동적 융합을 수행한다.



이 과정을 통해 모델은 "입력된 피부 사진을 볼 때, N 개의 파생변수 중 특히 '면적 대비 둘레 비율' 토큰에 높은 어텐션을 주어야겠다" 고 스스로 판단하여 D 차원의 강력한 베이스 융합 벡터(F_{base})를 도출한다.


Step 3. 오라클 잔차 추정 (Oracle Residual Estimation) - 핵심 기술

본 연구의 핵심으로, 무거운 자연어 모델(LLM) 배제하고 iddx_full의 계층적 Taxonomy (분류) 구조를 활용하여 완벽한 오라클 지식(F_{oracle})과 베이스 지식(F_{base})의 차이(R)를 학습한다.

1. 계층적 라벨 임베딩 (Hierarchical Label Embedding): 0.98%의 샘플에 한정하여, iddx_full 문자열을 :: 기준으로 분해한다(예: Level 1 :: Level 2 :: Level 3). 각 레벨 별로 독립적인 임베딩 레이어를 학습시키고, 이들을 어텐션(Attention)으로 결합하여 단일 오라클 경로 표상(Oracle Path Representation, E_{path})을 생성한다.
2. Teacher Adapter를 통한 오라클 델타(Δ_{oracle}) 추출: 도출된 E_{path} 를 F_{base} 와 결합한 후, Train-Only Teacher Adapter(MLP)를 통과시켜 D 차원의 델타 벡터를 추출한다. ($\Delta_{oracle} = Adapter(Concat(F_{base}, E_{path}))$)
3. 잔차(R)의 확정적 정의: 완벽한 오라클 벡터 F_{oracle} 을 $F_{base} + \Delta_{oracle}$ 로 정의(Define)함으로써 두 벡터가 태생적으로 같은 잠재 공간을 공유하도록 강제한다. 따라서 잔차 R 은 자연스럽게 Δ_{oracle} 과 일치하게 된다. ($R = F_{oracle} - F_{base} = \Delta_{oracle}$)
4. 보조 네트워크 (Student) 학습: 내부의 잔차 추정기(Residual Estimator)는 오직 Strict Feature Engineering Dataset의 복잡한 파생변수 패턴만을 입력받아, 결측될 오라클 잔차의 근사치($\hat{R}$)를 회귀(Regression) 추정하도록 MSE Loss로 학습된다.

[BORE 아키텍처 요약]

BORE (Bayesian-initialized Oracle Residual Estimation) 모델은 결측된 1% 미만의 희소 오라클 데이터를 억지로 복원하는 대신, '통계적 힌트 주입'과 '빈 공간(잔차) 유추'라는 두 가지 간접적인 방식으로 임상 지식을 네트워크에 증류(Distillation)합니다.



■ 실험적 방어 전략 (Experimental Defense Strategy)

초희소 데이터를 다루는 본 연구 특성상, 발생할 수 있는 실패 위험에 대비하여 다음과 같은 다중 방어 전략을 실험에 포함합니다.

1. Ablation Study (절제 연구): 사전 학습된 FT-Transformer를 활용한 '베이지안 초기화' 유무에 따른 학습 곡선(Learning Curve)을 비교하여, 0.98% 희소 데이터 환경에서의 모델 수렴 속도 개선 효과를 입증한다.
2. 파생변수(Strict Feature Engineering)를 통한 하한선(Lower Bound) 방어: 보조 네트워크의 잔차 추정이 일부 빗나가 노이즈($\hat{R} \approx \text{error}$)가 발생하더라도, *tbp_lv_area_perim_ratio*, *tbp_lv_deltaLBnorm* 등 도메인 지식으로 구축된 파생변수들이 Cross-Attention을 통해 F_{base} 의 예측력을 굳건히 지탱하여 전체 성능(pAUC)이 베이스라인 이하로 붕괴하지 않는 '우아한 실패(Graceful Degradation)' 구조를 증명한다.
- 원리 (수식적 방어): 최종 진단에 사용되는 벡터는 $F_{\text{base}} + \hat{R}$ 입니다. 만약 잔차 추정기가 학습에 실패하여 $\hat{R}$ 이 의미 없는 무작위 노이즈(Noise)가 되었다고 가정해 봅시다.

단순한 원시 데이터로 F_{base} 를 만들었다면 노이즈에 휩쓸려 분류기가 붕괴(오답 남발)합니다. 하지만 본 연구는 $tbp_lv_area_perim_ratio$ (면적 대비 둘레), $tbp_lv_deltaLBnorm$ (색상 대비)처럼 강력한 임상적 시그널을 가진 파생변수로 F_{base} 를 구축했습니다. Cross-Attention을 통해 이 파생변수들이 굳건히 중심을 잡고 있기 때문에, $\hat{R}$ 에 약간의 노이즈가 끼어도 피부암을 판별하는 거대한 결정 경계(Decision Boundary)는 흔들리지 않습니다.

● 실험적 증명 (논문에 들어갈 실험 셋업):

- 1) 실험 A (정상): $F_{base} + \hat{R}$ (정상 추정된 잔차)를 사용하여 최고 성능 도출.
 - 2) 실험 B (노이즈 주입): 의도적으로 $\hat{R}$ 대신 무작위 가우시안 노이즈(Random Gaussian Noise)나 영벡터($\vec{0}$)를 강제로 주입합니다.
 - 3) 결과 비교: 노이즈를 주입한 '실험 B'의 결과(pAUC)가 떨어지긴 하겠지만, 기존 캐글의 단순 이미지 베이스라인(Image-only ResNet 등)이나 원시 데이터 앙상블 모델의 성능보다는 여전히 높거나 같음(Lower Bound 방어)을 보여줍니다.
- 결론 도출: "우리의 잔차 추정이 실패하더라도, 정교하게 설계된 파생변수(Strict Dataset) 융합 구조가 방파제 역할을 하여 환자 진단에 치명적인 오진을 막아낸다."

3. Plan-C (Soft Probability Estimation): 잔차 벡터 회귀 추정이 최종적으로 수렴하지 않을 최악의 경우, 잔차 추정기를 '특정 k 개 Taxonomy Path에 속할 확률(Scalar)'을 예측하는 모듈로 전환하여 다중모달 융합의 어텐션 가중치(Attention Weight)로 사용하는 실험 방어전략을 세운다.

● 출력층(Output Layer)의 변경:

- 1) Plan-A (기존): 잔차 추정기의 출력이 트랜스포머의 잠재 차원과 같은 768차원 연속형 벡터($\hat{R}$).
- 2) Plan-C (전환): 잔차 추정기의 마지막 레이어를 변경하여, 출력값을 k 개(iddx_full의 범주 개수)의 스칼라 확률값 묶음(52-dimensional vector with Softmax/Sigmoid)으로 바꿉니다.

● 예측 목표의 변경:

- 1) 고차원의 잔차 벡터를 정확히 그리는 것을 포기하고, "이 환자의 파생변수를 보니, 조직검사를 하면 52개의 Taxonomy Path 중 3번 Path(예: Benign :: Nevus)가 나올 확률이 80%다"라는 확률값 p 를 구하게 합니다.

● 융합 방식의 변경 (Attention Weighting):

- 1) 기존의 덧셈($F_{base} + \hat{R}$)을 폐기합니다.
- 2) 대신, Step 1에서 초기화해 둔 k 개의 프로토타입 토큰($p_1 \dots p_k$)에 방금 구한 확률값 p 를 가중치(Weight)로 곱하여 모두 더합니다. (즉, 확률 기반의 가중합(Weighted Sum)을 수행합니다.)

3) 새로운 융합 수식: $F_{final} = F_{base} + \sum_{i=1}^k (p_i \cdot P_i)$

4. 설명 가능한 AI (xAI) 검증: 추정된 오라클 잔차($\hat{R}$)가 파생변수 중 어떤 임상적 특징에 가장 큰 어텐션 가중치를 부여했는지 SHAP 기법과 Attention Map을 통해 시각화한다. 이를 통해 블랙박스 유추 과정을 해독하고, 모델의 유추가 의료진의 임상적 직관과 일치함을 정성적으로 입증한다.

III. 참고문헌

1. Kurtansky, N. R., et al. (2024). The SLICE-3D dataset: 400,000 skin lesion image crops extracted from 3D TBP for skin cancer detection. *Scientific Data*, 11(1), 884.
2. ISIC 2024 Challenge. (2024). Skin Cancer Detection with 3D-TBP. Kaggle.
3. Du, S., et al. (2024). TIP: Tabular-Image Pre-training for Multimodal Classification with Incomplete Data. arXiv preprint arXiv:2407.07582.
4. Gorishniy, Y., et al. (2021). Revisiting deep learning models for tabular data. *Advances in Neural Information Processing Systems*, 34, 18932-18943.
5. Silla, C. N., & Freitas, A. A. (2011). A survey of hierarchical classification across different application domains. *Data Mining and Knowledge Discovery*, 22(1-2), 31-72.
6. He, K., et al. (2016). Deep residual learning for image recognition. In *CVPR* (pp. 770-778).
7. Friedman, N., et al. (1997). Bayesian network classifiers. *Machine Learning*, 29(2-3), 131-163.
8. Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
9. Tsai, Y. H. H., et al. (2019). Multimodal machine learning with aligned and unaligned representations. In *ACL* (pp. 5132-5143).