

Label Graph Metric Multimodal Model

수식 기반 모델 정식화 문서

작성 목적: test 시점에 `iddx_full` 없이 image + strict tabular 만으로 악성 여부와 악성 subtype 을 추정하는 단일 모델 구성

핵심 요약. 이 문서는 `iddx_full` 을 test-time input 으로 사용하지 않고, train-time privileged label knowledge 로만 사용하는 모델을 수식화한다. 전체 구조는 다음과 같다.

$$\begin{aligned} (I_i, X_i^{\text{strict}}) &\xrightarrow{\text{image/tabular encoders}} f_i^{\text{base}} \xrightarrow{\text{label graph metric}} a_i, \\ (f_i^{\text{base}}, a_i) &\xrightarrow{\text{gated fusion}} f_i^{\text{final}} \xrightarrow{\text{heads}} (p_i^{\text{mal}}, p_i^{\text{subtype}}). \end{aligned}$$

학습 중에는 `iddx_full` 로 라벨 그래프와 metric target 을 만들지만, 추론 중에는 이미지와 strict tabular 만 들어간다. 학습된 label embedding 은 classifier prototype 처럼 남아 악성 subtype 점수를 계산하는 데 사용된다.

Contents

1 문제 설정: train/test 정보 비대칭	4
1.1 사용 가능한 정보	4
1.2 목표	4
2 기호와 차원 정의	4
3 Base representation: image 를 Query, tabular 를 Key/Value 로 쓰는 cross-attention	6
3.1 Image encoder	6
3.2 Tabular encoder	6
3.3 Multi-head cross-attention	6
3.4 Base representation 의 의미	7
4 idx_full label hierarchy 를 graph 로 정의	7
4.1 계층 label path	7
4.2 Graph node 와 edge	8
4.3 Graph distance	8
5 Label embedding 과 graph encoder	8

5.1 초기 label embedding	8
5.2 GCN-style graph message passing	9
5.3 R-GCN-style edge type 확장	9
6 Graph regularization: label embedding 공간 안정화	9
6.1 Parent-child smoothness loss	9
6.2 Distance-preserving regularization	10
6.3 Negative separation loss	10
6.4 최종 graph regularization	10
7 Metric learning: sample embedding 과 label embedding 정렬	10
7.1 Sample 을 label space 로 projection	10
7.2 Sample-label similarity	11
7.3 Hierarchy-aware soft target	11
7.4 Label contrastive / graph-aware CE loss	11
7.5 Hierarchy-aware triplet loss	11
7.6 최종 metric objective	12
8 Label-aware auxiliary representation	12
8.1 Predicted label distribution	12
8.2 Auxiliary representation	12
8.3 Benign collapse 방지용 null auxiliary	12
9 Base representation 과 auxiliary representation 의 단일 모델 결합	13
9.1 Gated correction fusion	13
9.2 왜 residual correction 인가	13
9.3 Correction magnitude regularization	13
10 Binary malignant head 와 malignant subtype head	14
10.1 Binary malignant head	14
10.2 Malignant subtype head: label embedding 을 classifier prototype 으로 사용	14
10.3 Joint malignant subtype probability	14
10.4 Subtype head 의 의미	14
11 Loss function 전체 연결	15
11.1 Binary malignant loss	15
11.2 Malignant subtype loss	15

11.3 Graph 와 metric auxiliary loss	15
11.4 최종 전체 목적함수	16
12 End-to-end 수식 흐름	16
13 학습 알고리즘	16
13.1 Fold-local 사전 준비	16
13.2 Mini-batch training step	17
14 추론 알고리즘	17
15 Prototype-weighted 대안 구조	18
15.1 Cluster 또는 label prototype	18
15.2 Prototype mixture correction	18
16 차원 검증 예시	19
17 권장 ablation 설계	19
18 최종 핵심 수식 모음	20
18.1 Base representation	20
18.2 Label graph embedding	20
18.3 Metric alignment	20
18.4 Graph regularization	20
18.5 Auxiliary representation 과 final representation	20
18.6 Output heads	20
18.7 Total loss	21
19 짧은 결론	21

1 문제 설정: train/test 정보 비대칭

1.1 사용 가능한 정보

각 병변 샘플을 $i = 1, \dots, N$ 이라고 한다. 연구 설정은 다음과 같다.

구분	학습 시점	추론/test 시점
입력 이미지	I_i 사용 가능	I_i 사용 가능
strict tabular	X_i^{strict} 사용 가능	X_i^{strict} 사용 가능
악성 여부 label	$y_i^{\text{mal}} \in \{0, 1\}$ 사용 가능	없음. 모델이 예측
계층 병리 label	$\ell_i = \text{iddx_full}_i$ 사용 가능	없음. 모델 입력으로 사용 금지

따라서 `iddx_full` 은 입력 branch 가 아니라 **train-time privileged supervision** 이다. 모델은 다음 함수를 학습한다.

$$\begin{aligned} \Phi_\theta : (I_i, X_i^{\text{strict}}) &\mapsto (p_i^{\text{mal}}, p_i^{\text{subtype}}, f_i^{\text{final}}), \\ p_i^{\text{mal}} &\in (0, 1), \\ p_i^{\text{subtype}} &\in \Delta^{K_M-1}. \end{aligned}$$

여기서 p_i^{mal} 은 악성 확률이고, p_i^{subtype} 은 악성이라고 판단될 때 어떤 악성 subtype 인지에 대한 조건부 분포이다. K_M 은 학습 데이터에서 관측된 malignant leaf label 수이다.

1.2 목표

학습 목표는 세 가지를 동시에 만족하는 것이다.

1. **배치 가능성**: 추론 시에는 $(I_i, X_i^{\text{strict}})$ 만 사용한다.
2. **병리 의미 활용**: 학습 중 `iddx_full` 의 계층 구조를 label graph 와 label embedding 으로 학습한다.
3. **악성 subtype 보조 추론**: 악성일 경우 label embedding 과 metric similarity 를 이용해 subtype ranking 을 제공한다.

2 기호와 차원 정의

본 문서에서는 row-vector convention 을 사용한다. 즉, 토큰 행렬은 “토큰 수 $\times$ feature 차원” 형태로 쓴다.

기호	차원	의미
B	scalar	mini-batch size
I_i	$\mathbb{R}^{3 \times H_{img} \times W_{img}}$	i 번째 병변 이미지

X_i^{strict}	$\mathbb{R}^p$ plus categorical fields	test 시점에 확보 가능한 tabular 입력. 예: $p = 51$ strict features
n_I	scalar	image token 수. ViT patch token + CLS 기준
n_T	scalar	tabular token 수. feature token + optional CLS 기준
d	scalar	공통 hidden dimension
H	scalar	attention head 수
d_h	d/H	head 하나의 차원
H_i^I	$\mathbb{R}^{n_I \times d}$	image encoder 출력 token sequence
H_i^T	$\mathbb{R}^{n_T \times d}$	tabular encoder 출력 token sequence
Q_i	$\mathbb{R}^{n_q \times d}$	image로부터 얻은 attention query. 보통 $n_q = 1$ 또는 $n_q = n_I$
K_i, V_i	$\mathbb{R}^{n_T \times d}$	tabular로부터 얻은 attention key/value
f_i^{base}	$\mathbb{R}^d$	image-query/tabular-key-value cross-attention 으로 얻은 base representation
$\mathcal{G} = (\mathcal{V}, \mathcal{E})$	graph	idx_full 계층으로 만든 label graph
$N_G = \mathcal{V} $	scalar	graph node 수. internal node 와 leaf node 모두 포함
K	scalar	informative leaf label 수
K_M	scalar	malignant leaf label 수
Z	$\mathbb{R}^{N_G \times d}$	graph encoder 이후 모든 label node embedding
Z_L	$\mathbb{R}^{K \times d}$	leaf label embedding matrix
Z_M	$\mathbb{R}^{K_M \times d}$	malignant leaf label embedding matrix
u_i	$\mathbb{R}^d$	sample 을 label space 로 projection 한 embedding
a_i	$\mathbb{R}^d$	label-aware auxiliary representation
f_i^{final}	$\mathbb{R}^d$	최종 분류 표현
y_i^{mal}	$\{0, 1\}$	악성 여부 target
y_i^L	$\{1, \dots, K\}$	informative leaf label index
y_i^M	$\{1, \dots, K_M\}$	malignant subtype leaf index
m_i^L	$\{0, 1\}$	informative idx_full loss mask
m_i^M	$\{0, 1\}$	malignant subtype loss mask

Mask 의 역할. 대부분의 idx_full 이 단순 Benign 에 몰리면 label metric loss 가 giant benign class 로 붕괴할 수 있다. 따라서 label graph/metric loss 는 보통 $m_i^L = 1$ 인 pathology-informative sample 에만 적용하고, binary malignant loss 는 전체 sample 에 적용한다.

3 Base representation: image 를 Query, tabular 를 Key/-Value 로 쓰는 cross-attention

3.1 Image encoder

이미지 인코더를 E_I 라고 하자. 예를 들어 ViT 계열이면 patch token 과 CLS token 을 출력한다.

$$H_i^I = E_I(I_i) \in \mathbb{R}^{n_I \times d}.$$

image token 전체를 query 로 쓸 수도 있고, CLS token 만 query 로 쓸 수도 있다.

$$\bar{H}_i^I = \text{SelectQueryTokens}(H_i^I) \in \mathbb{R}^{n_q \times d},$$

여기서 $n_q = 1$ 이면 image CLS 만 query 로 쓰는 구조이고, $n_q = n_I$ 이면 모든 image token 이 tabular token 을 attend 한다.

3.2 Tabular encoder

strict tabular input 은 numeric/categorical preprocessing 후 tabular token sequence 로 변환된다. FT-Transformer 류 tabular encoder 를 E_T 라고 하면,

$$H_i^T = E_T(X_i^{\text{strict}}) \in \mathbb{R}^{n_T \times d}.$$

예를 들어 $p = 51$ 개의 feature token 과 tabular CLS 를 쓰면 $n_T = 52$ 가 될 수 있다. 범주형 변수는 embedding lookup, 수치형 변수는 feature-wise linear embedding 으로 token 화할 수 있다.

3.3 Multi-head cross-attention

head $h = 1, \dots, H$ 에 대해 projection matrix 를

$$W_Q^{(h)}, W_K^{(h)}, W_V^{(h)} \in \mathbb{R}^{d \times d_h}, \quad d_h = \frac{d}{H}$$

라고 둔다. 그러면

$$\begin{aligned} Q_i^{(h)} &= \bar{H}_i^I W_Q^{(h)} \in \mathbb{R}^{n_q \times d_h}, \\ K_i^{(h)} &= H_i^T W_K^{(h)} \in \mathbb{R}^{n_T \times d_h}, \\ V_i^{(h)} &= H_i^T W_V^{(h)} \in \mathbb{R}^{n_T \times d_h}. \end{aligned}$$

attention weight 와 head output 은 다음과 같다.

$$\begin{aligned} A_i^{(h)} &= \text{softmax} \left(\frac{Q_i^{(h)} (K_i^{(h)})^\top}{\sqrt{d_h}} \right) \in \mathbb{R}^{n_q \times n_T}, \\ C_i^{(h)} &= A_i^{(h)} V_i^{(h)} \in \mathbb{R}^{n_q \times d_h}. \end{aligned}$$

모든 head 를 concat 한 뒤 output projection 을 적용한다.

$$C_i = \text{Concat} \left(C_i^{(1)}, \dots, C_i^{(H)} \right) W_O, \quad W_O \in \mathbb{R}^{d \times d},$$

$$C_i \in \mathbb{R}^{n_q \times d}.$$

residual 과 MLP block 을 적용하면 cross-attended image-token representation 이 된다.

$$\tilde{H}_i^I = \text{LN} \left(\bar{H}_i^I + C_i \right) \in \mathbb{R}^{n_q \times d}.$$

이후 pooling 을 통해 vector 로 만든다.

$$h_i^{\text{cross}} = \text{Pool}(\tilde{H}_i^I) \in \mathbb{R}^d.$$

최종 base representation 은 다음과 같이 정의한다.

$$\boxed{f_i^{\text{base}} = \text{LN} \left(h_i^{\text{cross}} + \text{MLP}_{\text{base}}(h_i^{\text{cross}}) \right) \in \mathbb{R}^d}$$

3.4 Base representation 의 의미

f_i^{base} 는 이미지가 query 역할을 하고 strict tabular 가 key/value 역할을 하는 표현이다. 즉, 이미지가 병변의 시각적 단서를 제공하고 tabular token 이 그 시각적 단서의 해석 방향을 조정한다.

$$\text{image lesion pattern} \xrightarrow{\text{asks}} \text{tabular clinical context}.$$

이 표현만으로도 binary malignant classification 을 할 수 있지만, 초희귀 계층 label 의 의미 구조는 아직 직접 반영되어 있지 않다. 다음 단계가 이 부분을 보완한다.

4 iddx_full label hierarchy 를 graph 로 정의

4.1 계층 label path

iddx_full 문자열은 계층 path 로 해석한다. 예시는 다음과 같다.

$$\ell_i = \text{Malignant}::\text{Adnexal epithelial}::\text{Basal cell carcinoma}::\text{Nodular}.$$

이를 delimiter :: 로 나누면

$$\ell_i = (v_{i,1}, v_{i,2}, \dots, v_{i,L_i})$$

이고, prefix node 는

$$\pi_{i,1} = v_{i,1},$$

$$\pi_{i,2} = v_{i,1}::v_{i,2},$$

$$\vdots$$

$$\pi_{i,L_i} = v_{i,1}::\dots::v_{i,L_i}.$$

leaf label 은 π_{i,L_i} 이다.

4.2 Graph node 와 edge

전체 graph node set 은 모든 prefix node 의 합집합으로 정의한다.

$$\mathcal{V} = \bigcup_{i:m_i^L=1} \{\pi_{i,1}, \dots, \pi_{i,L_i}\} \cup \{v_\emptyset\}.$$

여기서 $v_\emptyset$ 는 Benign 과다 class 붕괴를 막기 위한 optional null/no-correction node 이다.
edge 는 parent-child 관계로 정의한다.

$$\mathcal{E}_{pc} = \{(\pi_{i,j}, \pi_{i,j+1}) \mid i : m_i^L = 1, j = 1, \dots, L_i - 1\}.$$

필요하면 sibling edge 도 추가할 수 있다.

$$\mathcal{E}_{sib} = \{(u, v) \mid \text{parent}(u) = \text{parent}(v), u \neq v\}.$$

최종 edge set 은

$$\mathcal{E} = \mathcal{E}_{pc} \cup \lambda_{sib} \mathcal{E}_{sib}$$

처럼 둘 수 있다. 실제 구현에서는 edge type 별 weight 를 따로 둔다.

4.3 Graph distance

두 label node $u, v \in \mathcal{V}$ 사이의 shortest-path distance 를

$$d_{\mathcal{G}}(u, v)$$

라고 하자. 이 거리는 metric learning 에서 “얼마나 나쁜 negative 인가” 를 정하는 기준이 된다.
예를 들어 같은 malignant family 의 subtype 은 가까운 negative 이고, malignant 와 benign 계열은 먼 negative 이다.

5 Label embedding 과 graph encoder

5.1 초기 label embedding

각 graph node $v \in \mathcal{V}$ 에 초기 embedding 을 둔다.

$$Z^{(0)} = \left[z_v^{(0)} \right]_{v \in \mathcal{V}} \in \mathbb{R}^{N_G \times d_0}.$$

초기화는 세 가지 중 하나를 쓸 수 있다.

1. learnable node embedding: $z_v^{(0)} = \text{Embed}(v)$
2. label text encoder embedding: $z_v^{(0)} = \text{TextEnc}(\text{name}(v))$
3. 두 값을 결합: $z_v^{(0)} = W_e[\text{Embed}(v); \text{TextEnc}(v)]$

초기에는 learnable embedding 만으로 시작해도 되지만, 초희귀 label 이 많다면 label text encoder 를 섞는 방식이 더 안정적일 수 있다.

5.2 GCN-style graph message passing

Adjacency matrix 를 $A \in \mathbb{R}^{N_G \times N_G}$, self-loop 를 포함한 adjacency 를 $\tilde{A} = A + I$, degree matrix 를 $\tilde{D}$ 라고 하자.

$$\tilde{D}_{vv} = \sum_u \tilde{A}_{vu}.$$

정규화 adjacency 는

$$\hat{A} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} \in \mathbb{R}^{N_G \times N_G}.$$

r 번째 graph layer 는 다음과 같다.

$$Z^{(r+1)} = \phi \left(\hat{A} Z^{(r)} W_G^{(r)} \right)$$

여기서

$$Z^{(r)} \in \mathbb{R}^{N_G \times d_r}, \quad W_G^{(r)} \in \mathbb{R}^{d_r \times d_{r+1}}.$$

R_G 개 layer 후 공통 dimension d 로 projection 하고 정규화한다.

$$Z = \text{Normalize} \left(Z^{(R_G)} W_Z \right) \in \mathbb{R}^{N_G \times d}$$

leaf label embedding 만 모으면

$$Z_L = \text{GatherLeaf}(Z) \in \mathbb{R}^{K \times d}, \quad Z_M = \text{GatherMalignantLeaf}(Z) \in \mathbb{R}^{K_M \times d}.$$

5.3 R-GCN-style edge type 확장

parent-child edge 와 sibling edge 를 구분하고 싶으면 relational GCN 형태로 쓴다.

$$z_v^{(r+1)} = \phi \left(W_0^{(r)} z_v^{(r)} + \sum_{\rho \in \mathcal{R}} \sum_{u \in \mathcal{N}_\rho(v)} \frac{1}{c_{v,u,\rho}} W_\rho^{(r)} z_u^{(r)} \right),$$

여기서 $\mathcal{R} = \{\text{parent, child, sibling}\}$ 같은 edge type 집합이다.

6 Graph regularization: label embedding 공간 안정화

단순히 parent-child 를 가깝게만 만들면 모든 label embedding 이 한 점으로 붕괴할 수 있다. 따라서 graph regularization 은 **closeness** 와 **separation** 을 함께 둔다.

6.1 Parent-child smoothness loss

부모-자식 label 은 가까워야 한다.

$$\mathcal{L}_{pc} = \frac{1}{|\mathcal{E}_{pc}|} \sum_{(u,v) \in \mathcal{E}_{pc}} \omega_{uv}^{pc} \|z_u - z_v\|_2^2$$

ω_{uv}^{pc} 는 edge weight 이다. 기본값은 1 로 둘 수 있다.

Matrix form 으로는 graph Laplacian $L = D - A$ 를 사용해

$$\mathcal{L}_{lap} = \text{tr}(Z^\top LZ)$$

라고 쓸 수 있다. 이는 연결된 node 의 embedding 차이를 줄이는 regularizer 이다.

6.2 Distance-preserving regularization

graph 에서 가까운 label 은 embedding cosine similarity 가 높고, graph 에서 먼 label 은 낮아야 한다. target similarity 를

$$\rho_{uv} = \exp\left(-\frac{dg(u, v)}{\eta_G}\right) \in (0, 1]$$

로 정의한다. 그러면

$$\mathcal{L}_{dist} = \frac{1}{|\mathcal{P}|} \sum_{(u, v) \in \mathcal{P}} (\cos(z_u, z_v) - \rho_{uv})^2$$

여기서 $\mathcal{P}$ 는 모든 pair 를 쓰면 너무 크므로 sampled node pair set 으로 둔다.

6.3 Negative separation loss

서로 다른 root 또는 graph 상 먼 label 은 margin 이상 떨어지게 만든다.

$$\mathcal{L}_{sep} = \frac{1}{|\mathcal{N}^-|} \sum_{(u, v) \in \mathcal{N}^-} [m_G - \|z_u - z_v\|_2]_+^2$$

$\mathcal{N}^-$ 는 distant negative pair set 이고, $[x]_+ = \max(x, 0)$ 이다.

6.4 최종 graph regularization

$$\mathcal{L}_{graph} = \lambda_{pc} \mathcal{L}_{pc} + \lambda_{dist} \mathcal{L}_{dist} + \lambda_{sep} \mathcal{L}_{sep}$$

실전 추천은 처음에는 $\mathcal{L}_{pc} + \mathcal{L}_{sep}$ 로 시작하고, 안정화 후 $\mathcal{L}_{dist}$ 를 추가하는 것이다.

7 Metric learning: sample embedding 과 label embedding 정렬

7.1 Sample 을 label space 로 projection

base representation 을 label embedding 과 같은 차원으로 projection 한다.

$$u_i = \text{Normalize}(W_U f_i^{\text{base}} + b_U) \in \mathbb{R}^d$$

leaf label embedding 도 unit norm 으로 둔다.

$$z_k = \text{Normalize}(Z_L[k]) \in \mathbb{R}^d.$$

7.2 Sample-label similarity

각 informative leaf label $k = 1, \dots, K$ 에 대해

$$s_{ik} = \frac{\mathbf{u}_i^\top \mathbf{z}_k}{\tau_L}$$

이고, 전체 logit vector 는

$$\mathbf{s}_i = \frac{\mathbf{u}_i Z_L^\top}{\tau_L} \in \mathbb{R}^K.$$

$\tau_L > 0$ 는 temperature 이다. 값이 작을수록 label 간 분리가 강해진다.

7.3 Hierarchy-aware soft target

희귀 label 에서는 hard one-hot target 만 쓰면 불안정할 수 있다. 정답 leaf y_i^L 와 다른 leaf k 사이의 graph distance 를 이용해 soft target 을 만든다.

$$q_{ik} = \frac{\exp(-d_G(y_i^L, k)/\eta_L)}{\sum_{j=1}^K \exp(-d_G(y_i^L, j)/\eta_L)}.$$

q_{ik} 는 같은 family subtype 에 작은 양의 확률을 주고, 완전히 먼 label 에는 거의 0 을 준다.

7.4 Label contrastive / graph-aware CE loss

label metric loss 는 informative sample 에 대해서만 적용한다.

$$\mathcal{L}_{metric}^{CE} = \frac{1}{\sum_i m_i^L} \sum_{i=1}^B m_i^L \omega_{y_i^L} \left[- \sum_{k=1}^K q_{ik} \log \text{softmax}(\mathbf{s}_i)_k \right]$$

여기서 $\omega_{y_i^L}$ 는 class-balanced weight 이다. 예를 들어 class count n_c 에 대해

$$\omega_c = \frac{1 - \beta}{1 - \beta n_c}, \quad \beta \in [0, 1)$$

로 둘 수 있다.

7.5 Hierarchy-aware triplet loss

Hard negative mining 을 명시하려면 triplet loss 를 추가한다. 정답 label 은 $z_{y_i^L}$, negative label 은 z_n 이라고 하자.

$$D(\mathbf{u}, \mathbf{z}) = 1 - \cos(\mathbf{u}, \mathbf{z}).$$

negative label n 에 대한 margin 은 graph distance 가 멀수록 크게 둔다.

$$m_{i,n} = m_0 + \beta_m \left(1 - \exp \left[-\frac{d_{\mathcal{G}}(y_i^L, n)}{\eta_m} \right] \right).$$

그러면

$$\mathcal{L}_{triplet} = \frac{1}{|\mathcal{T}|} \sum_{(i,n) \in \mathcal{T}} \left[D(\mathbf{u}_i, \mathbf{z}_{y_i^L}) - D(\mathbf{u}_i, \mathbf{z}_n) + m_{i,n} \right]_+$$

이다. $\mathcal{T}$ 는 mini-batch 에서 뽑은 hard negative pair set 이다.

7.6 최종 metric objective

$$\mathcal{L}_{metric} = \mathcal{L}_{metric}^{CE} + \lambda_{trip} \mathcal{L}_{triplet}$$

처음 구현에서는 $\lambda_{trip} = 0$ 으로 두고 graph-aware CE 만 학습한 뒤, subtype 구분이 약하면 triplet 을 추가하는 방식이 안정적이다.

8 Label-aware auxiliary representation

Metric learning 으로 sample embedding $\mathbf{u}_i$ 와 label embedding Z_L 이 같은 공간에 놓이면, label posterior 를 사용해 label-aware auxiliary representation 을 만들 수 있다.

8.1 Predicted label distribution

$$\pi_i^L = \text{softmax}(\mathbf{s}_i) \in \Delta^{K-1}.$$

이 값은 test 시점에도 계산 가능하다. 왜냐하면 $\mathbf{s}_i$ 는 $(I_i, X_i^{\text{strict}})$ 와 학습된 Z_L 로부터 계산되기 때문이다. test 시점의 `idxx_full` 은 필요 없다.

8.2 Auxiliary representation

$$\mathbf{a}_i = (\pi_i^L)^\top Z_L \in \mathbb{R}^d$$

즉, $\mathbf{a}_i$ 는 현재 sample 이 label graph 상 어떤 병리 의미 node 들과 가까운지를 평균한 representation 이다.

8.3 Benign collapse 방지용 null auxiliary

전체 label posterior 가 pathology-informative label 에만 정의되면 benign sample 도 억지로 어떤 병리 label 에 할당될 수 있다. 이를 막기 위해 null/no-correction node 를 추가할 수 있다.

$$Z_L^+ = \begin{bmatrix} Z_L \\ \mathbf{z}_\emptyset^\top \end{bmatrix} \in \mathbb{R}^{(K+1) \times d}.$$

이때

$$\pi_i^+ = \text{softmax} \left(\frac{\mathbf{u}_i (Z_L^+)^{\top}}{\tau_L} \right), \quad \mathbf{a}_i = (\pi_i^+)^{\top} Z_L^+.$$

$z_{\emptyset}$ 는 “어떤 rare pathology label 에도 강하게 붙지 않는 상태” 를 나타낸다.

9 Base representation 과 auxiliary representation 의 단일 모델 결합

9.1 Gated correction fusion

사용자가 원하는 최종 구조는 base representation 과 label-graph/metric auxiliary representation 을 하나의 모델 안에서 결합하는 것이다. 가장 안정적인 결합은 gated residual correction 이다.

먼저 correction vector 를 만든다.

$$\mathbf{r}_i = \text{MLP}_{corr} \left([\mathbf{f}_i^{\text{base}}; \mathbf{a}_i; \mathbf{f}_i^{\text{base}} \odot \mathbf{a}_i; |\mathbf{f}_i^{\text{base}} - \mathbf{a}_i|] \right) \in \mathbb{R}^d$$

여기서 $[\cdot; \cdot]$ 는 concat 이고, $\odot$ 는 element-wise product 이다.

sample-wise gate 는

$$\mathbf{g}_i = \text{sigmoid} \left(W_g [\mathbf{f}_i^{\text{base}}; \mathbf{a}_i] + \mathbf{b}_g \right) \in (0, 1)^d$$

로 둔다. 최종 representation 은

$$\mathbf{f}_i^{\text{final}} = \text{LN} \left(\mathbf{f}_i^{\text{base}} + \mathbf{g}_i \odot \mathbf{r}_i \right) \in \mathbb{R}^d$$

이다.

9.2 왜 residual correction 인가

$\mathbf{r}_i$ 는 `idxx_full` 을 복원하는 target residual 이 아니다. 이는 strict input 과 학습된 label graph space 로부터 추정된 **representation-level correction vector** 이다. 따라서 추론 시에도 계산 가능하다.

$$\text{test-time input } (I_i, X_i^{\text{strict}}) \Rightarrow \mathbf{f}_i^{\text{base}}, \mathbf{u}_i, \mathbf{a}_i, \mathbf{r}_i, \mathbf{f}_i^{\text{final}}.$$

9.3 Correction magnitude regularization

보정 벡터가 base representation 을 과도하게 망치지 않도록 크기 규제를 둔다.

$$\mathcal{L}_{corr} = \frac{1}{B} \sum_{i=1}^B \|\mathbf{g}_i \odot \mathbf{r}_i\|_2^2$$

이 항은 auxiliary 가 주 task 를 압도하는 것을 막는다.

10 Binary malignant head 와 malignant subtype head

10.1 Binary malignant head

최종 악성 확률은 별도 binary head 로 계산한다.

$$\alpha_i^{\text{mal}} = \mathbf{w}_{\text{mal}}^\top \mathbf{f}_i^{\text{final}} + b_{\text{mal}}, \quad p_i^{\text{mal}} = \text{sigmoid}(\alpha_i^{\text{mal}})$$

이 head 는 전체 sample 에 대해 학습한다. 최종 목적이 악성 여부 판단이므로, binary head 는 반드시 독립적으로 유지하는 것이 좋다.

10.2 Malignant subtype head: label embedding 을 classifier prototype 으로 사용

악성 subtype 은 malignant leaf embedding $Z_M \in \mathbb{R}^{K_M \times d}$ 을 classifier weight 처럼 사용한다. 먼저 final representation 을 subtype label space 로 projection 한다.

$$\mathbf{q}_i^M = \text{Normalize}(W_M \mathbf{f}_i^{\text{final}} + \mathbf{b}_M) \in \mathbb{R}^d.$$

malignant subtype logit 은

$$\mathbf{s}_i^M = \frac{\mathbf{q}_i^M Z_M^\top}{\tau_M} \in \mathbb{R}^{K_M}$$

이고,

$$p_i^{\text{subtype}} = \text{softmax}(\mathbf{s}_i^M) \in \Delta^{K_M-1}$$

이다.

10.3 Joint malignant subtype probability

악성일 확률과 subtype 조건부 확률을 곱하면 subtype 별 joint probability 가 된다.

$$P_i(k \text{ malignant subtype}) = p_i^{\text{mal}} \cdot p_i^{\text{subtype}}(k), \quad k \in \mathcal{L}_M$$

최종 decision 은 다음처럼 쓴다.

$$\hat{y}_i^{\text{mal}} = \mathbf{1}[p_i^{\text{mal}} \geq \theta], \quad \hat{k}_i = \arg \max_{k \in \mathcal{L}_M} p_i^{\text{subtype}}(k) \quad \text{if } \hat{y}_i^{\text{mal}} = 1.$$

10.4 Subtype head 의 의미

이 subtype 예측은 test-time iddx_full 을 읽는 것이 아니다. 학습된 label embedding 을 prototype 으로 삼아, 현재 sample representation 이 어떤 malignant label embedding 과 가장 가까운지를 계산하는 것이다.

11 Loss function 전체 연결

11.1 Binary malignant loss

class imbalance 가 심하므로 weighted BCE 또는 focal loss 를 쓴다. 기본 weighted BCE 는 다음과 같다.

$$\mathcal{L}_{mal} = \frac{1}{B} \sum_{i=1}^B \left[-w_1 y_i^{\text{mal}} \log p_i^{\text{mal}} - w_0 (1 - y_i^{\text{mal}}) \log (1 - p_i^{\text{mal}}) \right]$$

여기서 w_1 은 malignant class weight, w_0 은 non-malignant class weight 이다.

Focal form 으로 바꾸면

$$\mathcal{L}_{mal}^{\text{focal}} = \frac{1}{B} \sum_i -\alpha_{y_i} (1 - p_{t,i})^\gamma \log p_{t,i},$$

$$p_{t,i} = \begin{cases} p_i^{\text{mal}}, & y_i^{\text{mal}} = 1, \\ 1 - p_i^{\text{mal}}, & y_i^{\text{mal}} = 0. \end{cases}$$

11.2 Malignant subtype loss

악성 subtype label 이 있는 sample 에만 적용한다. mask 는

$$m_i^M = \mathbf{1}[y_i^{\text{mal}} = 1 \text{ and malignant leaf label exists}].$$

loss 는

$$\mathcal{L}_{sub} = \frac{1}{\sum_i m_i^M} \sum_{i=1}^B m_i^M \omega_{y_i^M}^M \left[-\log p_i^{\text{subtype}}(y_i^M) \right]$$

이다.

초희귀 subtype 에서는 hard CE 대신 graph-aware soft target 을 쓸 수 있다. malignant leaf 사이의 graph distance 를 이용해

$$q_{ik}^M = \frac{\exp[-d_{\mathcal{G}}(y_i^M, k)/\eta_M]}{\sum_{j \in \mathcal{L}_M} \exp[-d_{\mathcal{G}}(y_i^M, j)/\eta_M]}$$

로 두면,

$$\mathcal{L}_{sub}^{\text{soft}} = \frac{1}{\sum_i m_i^M} \sum_i m_i^M \omega_{y_i^M}^M \left[-\sum_{k \in \mathcal{L}_M} q_{ik}^M \log p_i^{\text{subtype}}(k) \right].$$

11.3 Graph 와 metric auxiliary loss

앞에서 정의한

$$\mathcal{L}_{\text{graph}}, \quad \mathcal{L}_{\text{metric}}, \quad \mathcal{L}_{\text{corr}}$$

를 함께 사용한다.

11.4 최종 전체 목적함수

$$\mathcal{L}_{total} = \mathcal{L}_{mal} + \lambda_{sub}\mathcal{L}_{sub} + \lambda_{metric}\mathcal{L}_{metric} + \lambda_{graph}\mathcal{L}_{graph} + \lambda_{corr}\mathcal{L}_{corr}$$

처음 실험에서는 다음처럼 단순한 버전부터 시작하는 것이 안전하다.

$$\mathcal{L}_{total}^{start} = \mathcal{L}_{mal} + 0.1\mathcal{L}_{metric}^{CE} + 10^{-3}\mathcal{L}_{corr} + 10^{-3}\mathcal{L}_{graph}.$$

그 후 subtype 해석을 강화하고 싶으면 $\mathcal{L}_{sub}$ 와 $\mathcal{L}_{triplet}$ 을 추가한다.

12 End-to-end 수식 흐름

한 sample i 에 대한 전체 forward pass 는 다음처럼 한 줄로 연결된다.

$$\begin{aligned} I_i &\xrightarrow{E_I} H_i^I \in \mathbb{R}^{n_I \times d}, \\ X_i^{strict} &\xrightarrow{E_T} H_i^T \in \mathbb{R}^{n_T \times d}, \\ (H_i^I, H_i^T) &\xrightarrow{\text{CrossAttn}(Q=I, K=T, V=T)} f_i^{base} \in \mathbb{R}^d, \\ \mathcal{G}(\text{iddx_full}) &\xrightarrow{\text{GNN+GraphReg}} Z_L, Z_M, \\ f_i^{base} &\xrightarrow{W_U} u_i \in \mathbb{R}^d, \\ (u_i, Z_L) &\xrightarrow{\text{MetricSimilarity}} \pi_i^L \in \Delta^{K-1}, \\ (\pi_i^L, Z_L) &\xrightarrow{\text{WeightedSum}} a_i \in \mathbb{R}^d, \\ (f_i^{base}, a_i) &\xrightarrow{\text{GatedCorrection}} f_i^{final} \in \mathbb{R}^d, \\ f_i^{final} &\xrightarrow{\text{BinaryHead}} p_i^{mal} \in (0, 1), \\ (f_i^{final}, Z_M) &\xrightarrow{\text{SubtypePrototypeHead}} p_i^{subtype} \in \Delta^{K_M-1}. \end{aligned}$$

전체 수식의 의미. Base branch 는 실제 test input 만으로 병변 표현을 만든다. Label graph branch 는 학습 데이터의 `iddx_full` 계층 구조를 embedding 공간으로 압축한다. Metric learning 은 base representation 이 이 label embedding 공간과 정렬되도록 만든다. Auxiliary representation a_i 는 “현재 병변이 label graph 상 어떤 병리 의미와 가까운지” 를 표현한다. 최종 representation f_i^{final} 는 base 표현을 유지하면서 label-aware correction 을 제한적으로 더한 것이다. 따라서 추론 시에는 `iddx_full` 없이도 악성 여부와 악성 subtype ranking 을 함께 출력할 수 있다.

13 학습 알고리즘

13.1 Fold-local 사전 준비

각 fold 에서 반드시 training split 만 사용해 다음을 만든다.

1. strict tabular 전처리: imputer, scaler, categorical vocabulary

2. informative label set $\mathcal{L}$ 와 malignant label set $\mathcal{L}_M$
3. label graph $\mathcal{G} = (\mathcal{V}, \mathcal{E})$
4. class count 기반 weights $w_0, w_1, \omega_c, \omega_c^M$

validation/test 에는 training split 에서 fit 된 변환과 graph index 만 적용한다.

13.2 Mini-batch training step

mini-batch $\mathcal{B}$ 에 대해:

1. image encoder 와 tabular encoder 로 H_i^I, H_i^T 계산
2. image-query/tabular-key-value cross-attention 으로 f_i^{base} 계산
3. label graph encoder 로 Z_L, Z_M 계산
4. $u_i = W_U f_i^{\text{base}}$ 와 label similarity s_i 계산
5. label posterior π_i^L 와 auxiliary representation a_i 계산
6. gated correction 으로 f_i^{final} 계산
7. binary malignant probability 와 subtype probability 계산
8. $\mathcal{L}_{\text{total}}$ 계산 후 backpropagation

14 추론 알고리즘

test sample 에는 `idx_full` 이 없다고 가정한다. 추론에서는 다음만 필요하다.

$$I_i, \quad X_i^{\text{strict}}, \quad \text{학습 완료된 } E_I, E_T, Z_L, Z_M, \text{ heads.}$$

수식은 다음과 같다.

$$\begin{aligned} f_i^{\text{base}} &= F_{\text{base}}(I_i, X_i^{\text{strict}}), \\ u_i &= \text{Normalize}(W_U f_i^{\text{base}} + b_U), \\ \pi_i^L &= \text{softmax}(u_i Z_L^\top / \tau_L), \\ a_i &= (\pi_i^L)^\top Z_L, \\ f_i^{\text{final}} &= \text{LN}(f_i^{\text{base}} + g_i \odot r_i), \\ p_i^{\text{mal}} &= \text{sigmoid}(w_{\text{mal}}^\top f_i^{\text{final}} + b_{\text{mal}}), \\ p_i^{\text{subtype}} &= \text{softmax}\left(\frac{\text{Normalize}(W_M f_i^{\text{final}} + b_M) Z_M^\top}{\tau_M}\right). \end{aligned}$$

결과 보고는 다음처럼 하면 된다.

$$\text{Report}_i = \left(p_i^{\text{mal}}, \text{TopK}_{k \in \mathcal{L}_M} P_i(k \text{ malignant subtype}) \right)$$

단, subtype 은 확진이 아니라 image+strict tabular 로부터 추정된 label-graph similarity 기반 보조 설명이다.

15 Prototype-weighted 대안 구조

Correction head 가 너무 자유도가 높다고 판단되면 prototype-weighted branch 를 대조 실험군으로 둘 수 있다. 이 구조는 fallback 이 아니라 안정성 비교용이다.

15.1 Cluster 또는 label prototype

malignant/informative leaf k 에 대해 training sample 의 base representation 평균을 prototype 으로 둘 수 있다.

$$\mathbf{p}_k = \text{Normalize} \left(\frac{1}{|S_k|} \sum_{i \in S_k} \mathbf{f}_i^{\text{base}} \right) \in \mathbb{R}^d.$$

또는 label embedding 을 그대로 prototype 으로 쓸 수 있다.

$$\mathbf{p}_k = \mathbf{z}_k.$$

15.2 Prototype mixture correction

$$\rho_i = \text{softmax}(W_P \mathbf{f}_i^{\text{base}} + \mathbf{b}_P) \in \Delta^{K_P-1},$$

$$\tilde{\mathbf{r}}_i = \sum_{k=1}^{K_P} \rho_{ik} \mathbf{p}_k \in \mathbb{R}^d.$$

null prototype 을 포함하면 benign sample 의 과도한 correction 을 줄일 수 있다.

$$\mathbf{f}_i^{\text{final,proto}} = \text{LN} \left(\mathbf{f}_i^{\text{base}} + \beta_i \tilde{\mathbf{r}}_i \right), \quad \beta_i = \text{sigmoid}(\mathbf{w}_\beta^\top \mathbf{f}_i^{\text{base}} + b_\beta).$$

16 차원 검증 예시

예를 들어 $d = 256$, attention head $H = 8$, $d_h = 32$, image CLS 만 query 로 사용하여 $n_q = 1$, tabular token 이 $n_T = 52$ 라고 하자.

$$\begin{aligned} H_i^I &\in \mathbb{R}^{n_I \times 256}, \\ \bar{H}_i^I &\in \mathbb{R}^{1 \times 256}, \\ H_i^T &\in \mathbb{R}^{52 \times 256}, \\ Q_i^{(h)} &\in \mathbb{R}^{1 \times 32}, \\ K_i^{(h)}, V_i^{(h)} &\in \mathbb{R}^{52 \times 32}, \\ A_i^{(h)} &\in \mathbb{R}^{1 \times 52}, \\ C_i^{(h)} &\in \mathbb{R}^{1 \times 32}, \\ C_i &\in \mathbb{R}^{1 \times 256}, \\ f_i^{\text{base}} &\in \mathbb{R}^{256}. \end{aligned}$$

label graph node 가 $N_G = 120$, informative leaf 가 $K = 45$, malignant leaf 가 $K_M = 20$ 이면,

$$Z \in \mathbb{R}^{120 \times 256}, \quad Z_L \in \mathbb{R}^{45 \times 256}, \quad Z_M \in \mathbb{R}^{20 \times 256}.$$

따라서

$$u_i Z_L^\top \in \mathbb{R}^{45}, \quad q_i^M Z_M^\top \in \mathbb{R}^{20}.$$

최종 출력은

$$p_i^{\text{mal}} \in (0, 1), \quad p_i^{\text{subtype}} \in \mathbb{R}^{20}, \quad \sum_{k=1}^{20} p_i^{\text{subtype}}(k) = 1.$$

17 권장 ablation 설계

모델이 복잡하므로 다음 순서로 단계별 검증을 권장한다.

단계	모델	검증 질문
A0	image-only	이미지 단독 기준 성능은 얼마인가?
A1	strict tabular-only	tabular 단독 기준 성능은 얼마인가?
A2	concat multimodal	단순 결합 기준 성능은 얼마인가?
A3	image-Q/tabular-KV cross-attention	cross-attention fusion 자체가 도움이 되는가?
B1	A3 + label metric loss	idxx_full auxiliary alignment 가 base representation 을 개선하는가?
B2	B1 + graph regularization	label graph 안정화가 rare subtype 표현을 안정화하는가?
C1	B2 + gated correction	auxiliary representation 을 최종 분류에 쓰는 것이 binary 악성 판단에 도움이 되는가?

C2	B2 + prototype-weighted correction	자유형 correction 보다 prototype 제한형이 더 안정적인가?
----	------------------------------------	---

18 최종 핵심 수식 모음

18.1 Base representation

$$\mathbf{f}_i^{\text{base}} = \text{LN} \left(\text{Pool} \left(\text{LN} \left(\bar{H}_i^I + \text{MHA}(Q = \bar{H}_i^I, K = H_i^T, V = H_i^T) \right) \right) + \text{MLP}_{\text{base}}(\cdot) \right).$$

18.2 Label graph embedding

$$Z^{(r+1)} = \phi(\hat{A}Z^{(r)}W_G^{(r)}), \quad Z = \text{Normalize}(Z^{(R_G)}W_Z).$$

18.3 Metric alignment

$$\mathbf{u}_i = \text{Normalize}(W_U \mathbf{f}_i^{\text{base}} + \mathbf{b}_U), \quad \mathbf{s}_i = \frac{\mathbf{u}_i Z_L^\top}{\tau_L}.$$

$$\mathcal{L}_{\text{metric}}^{CE} = \frac{1}{\sum_i m_i^L} \sum_i m_i^L \omega_{y_i^L} \left[- \sum_k q_{ik} \log \text{softmax}(\mathbf{s}_i)_k \right].$$

18.4 Graph regularization

$$\mathcal{L}_{\text{graph}} = \lambda_{pc} \frac{1}{|\mathcal{E}_{pc}|} \sum_{(u,v) \in \mathcal{E}_{pc}} \|\mathbf{z}_u - \mathbf{z}_v\|_2^2 + \lambda_{sep} \frac{1}{|\mathcal{N}^-|} \sum_{(u,v) \in \mathcal{N}^-} [m_G - \|\mathbf{z}_u - \mathbf{z}_v\|_2]_+^2 + \lambda_{dist} \mathcal{L}_{dist}.$$

18.5 Auxiliary representation 과 final representation

$$\boldsymbol{\pi}_i^L = \text{softmax} \left(\frac{\mathbf{u}_i Z_L^\top}{\tau_L} \right), \quad \mathbf{a}_i = (\boldsymbol{\pi}_i^L)^\top Z_L.$$

$$\mathbf{f}_i^{\text{final}} = \text{LN} \left(\mathbf{f}_i^{\text{base}} + \mathbf{g}_i \odot \text{MLP}_{\text{corr}} \left([\mathbf{f}_i^{\text{base}}; \mathbf{a}_i; \mathbf{f}_i^{\text{base}} \odot \mathbf{a}_i; |\mathbf{f}_i^{\text{base}} - \mathbf{a}_i|] \right) \right).$$

18.6 Output heads

$$p_i^{\text{mal}} = \text{sigmoid}(\mathbf{w}_{\text{mal}}^\top \mathbf{f}_i^{\text{final}} + b_{\text{mal}}).$$

$$p_i^{\text{subtype}} = \text{softmax} \left(\frac{\text{Normalize}(W_M \mathbf{f}_i^{\text{final}} + \mathbf{b}_M) Z_M^\top}{\tau_M} \right).$$

18.7 Total loss

$$\mathcal{L}_{total} = \mathcal{L}_{mal} + \lambda_{sub}\mathcal{L}_{sub} + \lambda_{metric}\mathcal{L}_{metric} + \lambda_{graph}\mathcal{L}_{graph} + \lambda_{corr}\mathcal{L}_{corr}$$

19 짧은 결론

이 모델은 기존의 단순 binary malignant classifier 에 계층형 label embedding space 를 붙이는 구조이다. 단, `idx_full` 을 test input 으로 넣지 않는다. 학습 중 `idx_full` 은 label graph, graph regularization, metric alignment, malignant subtype prototype 을 만드는 데 쓰인다. 추론 중에는 image encoder 와 strict tabular encoder 가 만든 base representation 이 label embedding space 와 비교되어 auxiliary representation 을 만들고, 이 representation 이 gated correction 을 통해 최종 binary malignant 판단과 malignant subtype ranking 을 보조한다.

가장 중요한 설계 원칙은 다음과 같다.

`idx_full` is supervision, not test-time input.

따라서 실제 배치 조건을 지키면서도 병리 label 의 계층 구조를 모델의 representation learning 에 활용할 수 있다.