

Data Engineering for Machine Learning

Final Homework - Wine Quality

포도주 품질 평가 데이터에 대한 기계학습을 진행하는 과제입니다.

예측 대상 필드는 Quality 입니다. 1~10까지 정수로 구분됩니다.

과제 요구 사항:

- 가능하면 적은 갯수의 필드로 Quality를 예측합니다.
- Quality 예측이 잘 되었는지 평가하는 기계학습 성능지표를 잘 선정해야 합니다.
- 학생이 선호하는 기계학습 알고리즘을 사용합니다.
- 사용하는 알고리즘이 파라미터를 많이 사용하는 것이라면, `mlflow`를 활용하는 것을 권장합니다.
- `mlflow` 사용했을 경우, `mlruns` 폴더 전체를 `zip` 파일로 archive 하여 제출합니다.
- 4000여개의 데이터를 제공하였고, 학생의 성과는 제공되지 않은 900여개의 데이터로 평가합니다.
- 간혹 이상치가 있을 수 있으니, 이상치를 제거하는 전처리 작업도 시행하여야 합니다.

제출물:

- 데이터 전처리 작업을 시행한 코드를 포함한 기계학습 전반의 모든 코드
- 전처리 방법과 기계학습에 사용된 알고리즘 및 그 학습성과를 모두 설명하는 최종보고서 (자유양식)

참고 사항:

Ajoupiterhub에서 `mlflow`를 사용하고자 하는 경우에는 `tracking uri`를 `file:///home/<your_ajou_email_id>/.mlflow` 로 설정해야, `mlflow contanier`에서 실험 결과를 확인할 수 있습니다.

아래 예시 코드 참조

```
if __name__ == "__main__":

    warnings.filterwarnings("ignore")
    np.random.seed(40)

    # Read the wine-quality csv file (make sure you're running this from the root
    of MLflow!)
    wine_path = os.path.join("./", "wine-quality.csv")
    data = pd.read_csv(wine_path)
    mlflow.set_tracking_uri("file:///home/jyc/.mlflow")
    mlflow.set_experiment(experiment_name="MLOPS-Final-2512")

    # Split the data into training and test sets. (0.75, 0.25) split.
    train, test = train_test_split(data)

    # The predicted column is "quality" which is a scalar from [3, 9]
    train_x = train.drop(["quality"], axis=1)
    test_x = test.drop(["quality"], axis=1)
```

```

train_y = train[["quality"]]
test_y = test[["quality"]]

alpha = 0.5
l1_ratio = 0.5

with mlflow.start_run():
    lr = ElasticNet(alpha=alpha, l1_ratio=l1_ratio, random_state=42)
    lr.fit(train_x, train_y)
    predicted_qualities = lr.predict(test_x)
    (rmse, mae, r2) = eval_metrics(test_y, predicted_qualities)

    print("Elasticnet model (alpha=%f, l1_ratio=%f):" % (alpha, l1_ratio))
    print(" RMSE: %s" % rmse)
    print(" MAE: %s" % mae)
    print(" R2: %s" % r2)

    mlflow.log_param("alpha", alpha)
    mlflow.log_param("l1_ratio", l1_ratio)
    mlflow.log_metric("rmse", rmse)
    mlflow.log_metric("r2", r2)
    mlflow.log_metric("mae", mae)

    mlflow.sklearn.log_model(lr, "model")

```

제출기한:

2025년 12월 23일 (수업 중 협의 후 변경 가능 - 앞당기는 변경만 가능)

데이터에 대한 설명

Wine 품질

- **fixed acidity**: 고정(비휘발성) 산도: 와인과 관련된 대부분의 산
- **volatile acidity**: 휘발성 산도: 와인에 함유된 아세트산의 양. 너무 높으면 불쾌한 식초 맛이 날 수 있음
- **citric acid**: 구연산: 소량으로 발견되며, 와인에 풍미를 더할 수 있음
- **residual sugar**: 잔여 당분: 발효가 멈춘 후 남은 설탕의 양으로 1g/L 미만의 와인은 드물며 45g/L 이상의 와인은 단맛으로 간주함
- **chlorides**: 염소화물: 와인의 염분량
- **free sulfur dioxide**: 유리 이산화황: 미생물의 성장과 와인의 산화를 방지함
- **total sulfur dioxide**: 총 이산화황: 저농도에서는 대부분 맛이 나지 않으나 50ppm 이상의 농도에서 맛에서 뚜렷하게 나타남
- **density**: 밀도: 알코올 및 당 함량에 따라 변함
- **pH**: 산성 또는 염기성 정도. 0(매우 산성) ~ 14(매우 염기성). 대부분의 와인은 pH 3-4 사이임
- **sulphates**: 황산염: 이산화황 농도에 기여할 수 있는 와인 첨가제. 향균 및 항산화제로 작용
- **alcohol**: 와인의 알코올 함량 백분율
- **quality**: 맛으로 평가된 와인의 품질